Université de Sorbonne Paris Nord **Algorithmique du texte** **Année 2021-2022**
Institut Galilée **Contrôle continu**

Toutes les réponses doivent être soigneusement justifiées.
La qualité de la rédaction interviendra de manière importante dans la notation.

Q1. On considère l'algorithme suivant :

```
tableau d'entiers  Algo1(string x)
0: entier m=taille(x)
1: MPnext[0] =-1
2: for i = 0 to m-1 do
3: j = MPnext[i].
4: while j >= 0 and x[i] != x[j] do
5: j = MPnext[j]
6: end while
7: MPnext[i+1] = j+1
8: end for
9: return MPnext
```

(*a*) Remplissez le tableau ci-dessous, en exécutant Algo1 pour chacun des mots *ababa*, *abcacabb*, *abcacababc*, *abacabacab* et en inscrivant dans chaque ligne le résultat retourné par l'algorithme.

strings	0	1	2	3	4	5	6	7	8	9	10
ababa											
abcacabb											
abcacababc											
abacabacab											

(*b*) Quelle est la complexité de Algo1 ?
(*c*) Quel est le tableau calculé par Algo1 ?

Q2. On considère l'algorithme suivant qui prend en entrée deux mots x et y et qui ne retourne rien. Dans cet exercice, on considère l'exécution de Algo2 avec $x = aba$ et $y = abcacacabac$.

```
Algo2 (string x, y)
0: m= taille(x) , n=taille(y)
1: i = 0, j = 0
2: while j < n do
3: while (i == m) or (i >= 0 and x[i] != y[j]) do
4: i = B[i]
5: end while
6: i = i+1
7: j = j+1
8: if i == m then
9: Afficher( x , "est present dans",  y,  "a la  position" , j-i )
10: end if
11: end while
```

(*a*) Remplir le tableau suivant concernant la phase de précalcul.

strings	0	1	2	3
x[i]	a	b	a	
B[i]				

(*a*) Remplir le tableau suivant concernant la phase de recherche (Les valeurs de $i$et j lors du test de la ligne 8, pendant exécution de Algo2 sur $x = aba$ et $y = abcacacabac$)

j	0	1	2	3	4	5	6	7	8	9	10
i											

(*d*) Quelle est la complexité de Algo2 ?
(*c*) Algo2 correspond-il à un algorithme vu en cours ?

Q3.

(a) On suppose avoir un motif unique. Citer des algorithmes pour rechercher efficacement ce motif dans des textes différents. Pour chaque algorithme, quels sont les temps de prétraitement et de traitement pour rechercher le motif de taille m dans k textes de tailles n ?

(b) On suppose avoir un texte unique. Citer des des algorithmes pour rechercher efficacement des motifs variés dans le texte. Pour chaque algorithme, quels sont les temps de prétraitement et de traitement pour rechercher dans le texte de tailles n, k motifs de taille m ?

(c) Soit $x =$ "*abaababa*". Donner la table des bords stricts BS de x ($BS[i]$ est la longueur du plus long bord strict de $x[0..i-1]$ relativement à x).

(d) Expliquez brièvement l'utilité de la table des bords stricts et rappeler l'algorithme pour la construire et sa complexité.

(e) Donner un automate pour reconnaître le mot *abaababa* dans un texte $t \in \{a, b\}^*$ et expliquer comment utiliser l'automate pour chercher le motif.

(f) Discutez de la possibilité d'appliquer la même méthode pour rechercher un ensemble fini de mots dans un texte ?

Q4. Simuler l'algorithme de Boyer-Moore vu en cours pour localiser les occurrences du motif $w = aba$ dans le texte $t = abcacacabac$.

(a) en utilisant uniquement la règle du mauvais caractère ;

(b) en utilisant uniquement la règle du bon suffixe ;

(c) en utilisant les deux règles.

Dans chaque cas, on précisera les résultats du précalcul, le cout du précalcul, ainsi que le cout total du calcul.

Q5. On considère l'alphabet $A = \{a, b, c\}$ et X un ensemble fini de mots construits sur A. L'automate de Aho-Corazik associé à l'ensemble X est noté $AC(X)$.

(a) Donner le trie construit avec les mots de l'ensemble $X = \{aa, abaabba, abb, bba\}$.

(b) Donner en justifiant les valeurs de la fonction de suppléance et de la fonction de sortie associées en chaque noeud du trie.

(c) Dessiner l'automate de Aho-Corasick associé à X.

(d) Donner un algorithme qui prend en entrée un automate de Aho-Corasick d'un ensemble X de motifs et un texte t de longueur n et qui recherche les motifs X dans le texte t. En donner la complexité.

Q6. On considère le mot $z = abaababa\$$.

(a) Donner le trie construit avec tous les suffixes de z. Quel est l'intérêt d'avoir ajouté un caractère de contrôle à la fin de z ?

(b) Soit n un entier (divisible par 4). Donner en justifiant la taille du trie des suffixes du mot $a^{(n/4)}b^{(n/4)}a^{(n/4)}b^{(n/4)}$.

(c) Quels sont les modifications à apporter au trie des suffixes pour obtenir l'arbre des suffixes. Donner un algorithme pour obtenir l'arbre des suffixes à partir du trie des suffixes. En donner la complexité après avoir détaillé la structure de données choisie pour le trie et pour l'arbre des suffixes.

(d) Quels sont la taille et le temps pour calculer l'arbre des suffixes d'un texte t de longueur n ?

(e) Donner un algorithme qui prend en entrée un motif w de longueur m et l'arbre des suffixes d'un texte t de longueur n et qui recherche le motif w dans le texte t. En donner la complexité.