Initiation à la recherche

CM5 : Protocole expérimental

Master 1 Informatique

Basarab Matei
matei@lipn.univ-paris13.fr

La Science Informatique

"*The discipline of computing is the systematic study of algorithmic processes that describe and transform information: their theory, analysis design, efficiency, implementation and application*"

Peter J. Denning et al. COMPUTING AS A DISCIPLINE

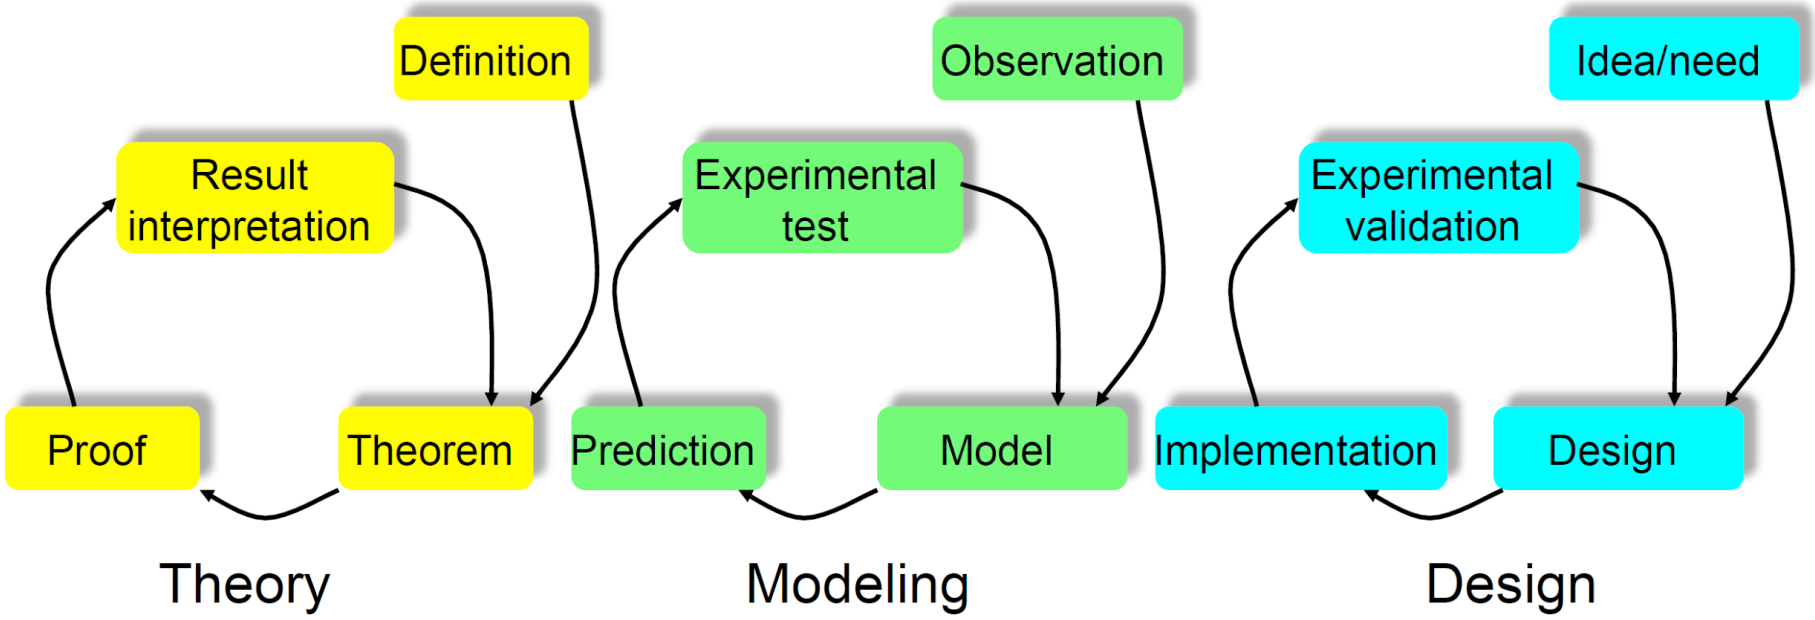
L'informatique n'est pas seulement une science, c'est aussi de l'ingénierie, de la technologie, etc (contrairement à la biologie ou la physique).

Deux manières de classer les connaissances:

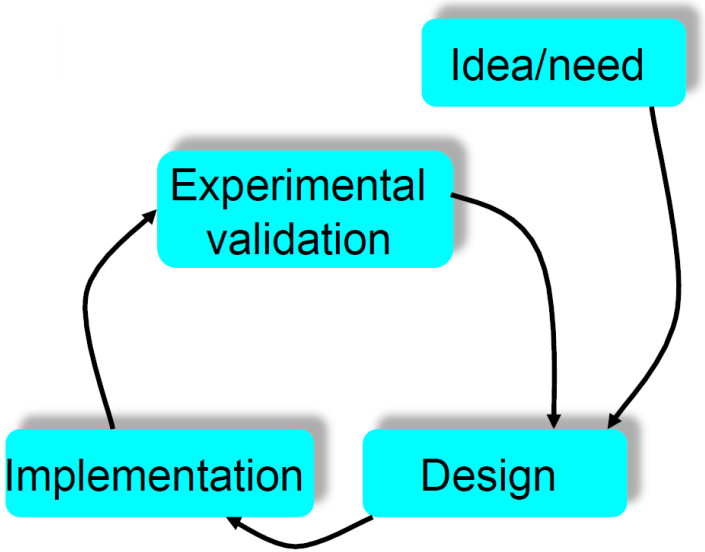
- **Analytique**: utilisation des mathématiques pour suivre des modèles
- **Expérimental**: recueillir des faits par l'observation

Trois paradigmes

Three feedback loops of the three paradigm of CS [Denning 89], [Feitelson 07]



La validation expérimentale



Design

Une bonne alternative à la validation analytique:

- Fournit une comparaison entre les algorithmes et les programmes.
- Fournit une validation du modèle ou aide à définir le domaine de validité du modèle.

La validation expérimentale

En informatique expérimentale, il est nécessaire de démontrer l'**efficacité** de la méthode que l'on propose par rapport aux algorithmes de l'état de l'art pour la résolution d'une catégorie de problème (tâche).

Pour démontrer cette efficacité, une validation expérimentale consiste à appliquer les différent algorithmes à un ensemble d'exemples (conditions expérimentales) de la catégorie de problème étudiée.

Les résultats des expériences sont évaluées selon un ensemble de **critères**, puis un bilan général est effectué.

Ma solution est meilleure

Efficiency	Workload A	Workload B	Workload C
My Solution	10	20	40
Your Solution	40	20	10

My Solution/Your Solution:

- Workload A: 0.25
- Workload B: 1
- Workload C: 4

Average: 5.25/3= 1.75

On average, My Solution is 1.75 more efficient than Your Solution

Propriétés d’une bonne expérience

Une bonne expérience doit avoir les propriétés suivantes :

- **Reproductibilité**: doit pouvoir être répétée et donner le même résultat.
- **Extensibilité**: doit cibler d'éventuelles comparaisons avec d'autres travaux et extensions (plus de / autres processeurs, ensembles de données plus volumineux, différentes architectures).
- **Applicabilité**: doit définir des paramètres réalistes et doit permettre un étalonnage facile.
- **«Révisibilité»**: lorsqu'une implémentation ne fonctionne pas comme prévu, doit aider à identifier les raisons.

Propriétés d'une bonne expérience

Contrôle:

- Essentiel pour savoir quelle partie de l'implémentation est évaluée.
- Permet de tester et d'évaluer chaque pièce indépendamment.

Reproductibilité:

- Base du protocole expérimental.
- Assuré par un environnement expérimental.

Réalisme:

- Condition expérimentale: toujours des conditions synthétiques.
- Trois niveaux de réalisme:
    1. Qualitative: l'expérience dit A1>A2 donc en réalité A1>A2
    2. Quantitative: l'expérience dit A1=k*A2 donc en réalité A1=k*A2
    3. Prédictive.
- Problème de la validation

Comparaisons d'algorithmes

TABLE III
VALUES OF THE NMI SCORE INDEX FOR EACH DATA SET AND DIFFERENT ALGORITHMS.

	HAC	Affinity	HDBSCAN	Spectral	Proposed
Art1	0.86	0.56	0.84	0.97	0.97
Art2	1.00	0.74	1.00	0.89	1.00
Art3	0.94	0.63	0.98	0.80	0.85
Iris	0.74	0.47	0.76	0.75	0.79
Digits	0.04	0.48	0.70	0.69	0.70
Wine	0.11	0.16	0.09	0.41	0.40
Prot1	0.96	0.50	0.90	0.96	0.96
Prot2	0.86	0.77	0.86	0.86	0.86
Prot3	0.92	0.38	0.78	0.92	0.91
Hist-mean	1.00	0.60	1.00	1.00	1.00
Hist-shape	0.03	0.19	0.38	0.73	0.78
Hist-std	1.00	0.46	1.00	1.00	1.00
People	0.02	0.00	0.64	0.57	0.93

Comparaisons d'algorithmes

TABLE III
VALUES OF THE NMI SCORE INDEX FOR EACH DATA SET AND DIFFERENT ALGORITHMS.

	HAC	Affinity	HDBSCAN	Spectral	Proposed
Art1	0.86	0.56	0.84	0.97	0.97
Art2	1.00	0.74	1.00	0.89	1.00
Art3	0.94	0.63	0.98	0.80	0.85
Iris	0.74	0.47	0.76	0.75	0.79
Digits	0.04	0.48	0.70	0.69	0.70
Wine	0.11	0.16	0.09	0.41	0.40
Prot1	0.96	0.50	0.90	0.96	0.96
Prot2	0.86	0.77	0.86	0.86	0.86
Prot3	0.92	0.38	0.78	0.92	0.91
Hist-mean	1.00	0.60	1.00	1.00	1.00
Hist-shape	0.03	0.19	0.38	0.73	0.78
Hist-std	1.00	0.46	1.00	1.00	1.00
People	0.02	0.00	0.64	0.57	0.93

Les algorithmes à tester

Il faut comparer la solution proposée avec les approches de l'état de l'art dont la qualité fait consensus pour cette tâche.

Comparaisons d'algorithmes

TABLE III
VALUES OF THE NMI SCORE INDEX FOR EACH DATA SET AND DIFFERENT ALGORITHMS.

	HAC	Affinity	HDBSCAN	Spectral	Proposed
Art1	0.86	0.56	0.84	0.97	0.97
Art2	1.00	0.74	1.00	0.89	1.00
Art3	0.94	0.63	0.98	0.80	0.85
Iris	0.74	0.47	0.76	0.75	0.79
Digits	0.04	0.48	0.70	0.69	0.70
Wine	0.11	0.16	0.09	0.41	0.40
Prot1	0.96	0.50	0.90	0.96	0.96
Prot2	0.86	0.77	0.86	0.86	0.86
Prot3	0.92	0.38	0.78	0.92	0.91
Hist-mean	1.00	0.60	1.00	1.00	1.00
Hist-shape	0.03	0.19	0.38	0.73	0.78
Hist-std	1.00	0.46	1.00	1.00	1.00
People	0.02	0.00	0.64	0.57	0.93

Les conditions expérimentales

Plus les conditions de test sont variées et nombreuses, plus les résultats obtenus sont fiable et généralisable.

Comparaisons d'algorithmes

TABLE III
VALUES OF THE NMI SCORE INDEX FOR EACH DATA SET AND DIFFERENT ALGORITHMS.

	HAC	Affinity	HDBSCAN	Spectral	Proposed
Art1	0.86	0.56	0.84	0.97	0.97
Art2	1.00	0.74	1.00	0.89	1.00
Art3	0.94	0.63	0.98	0.80	0.85
Iris	0.74	0.47	0.76	0.75	0.79
Digits	0.04	0.48	0.70	0.69	0.70
Wine	0.11	0.16	0.09	0.41	0.40
Prot1	0.96	0.50	0.90	0.96	0.96
Prot2	0.86	0.77	0.86	0.86	0.86
Prot3	0.92	0.38	0.78	0.92	0.91
Hist-mean	1.00	0.60	1.00	1.00	1.00
Hist-shape	0.03	0.19	0.38	0.73	0.78
Hist-std	1.00	0.46	1.00	1.00	1.00
People	0.02	0.00	0.64	0.57	0.93

Les mesure d'un critère de comparaison

Plus les conditions de test sont variées et nombreuses, plus les résultats obtenus sont fiable et généralisable.

Test statistique

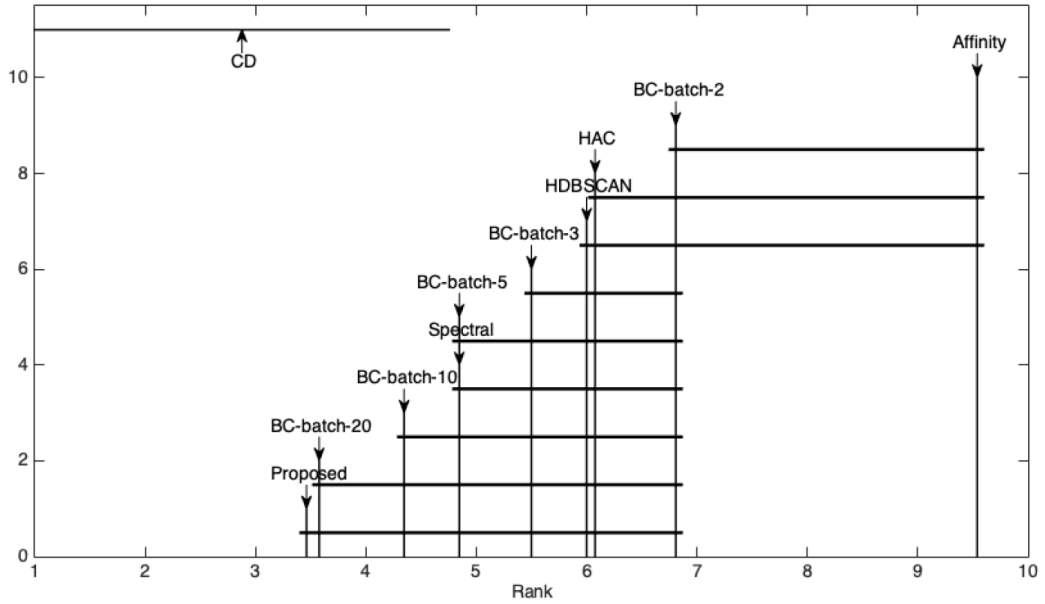
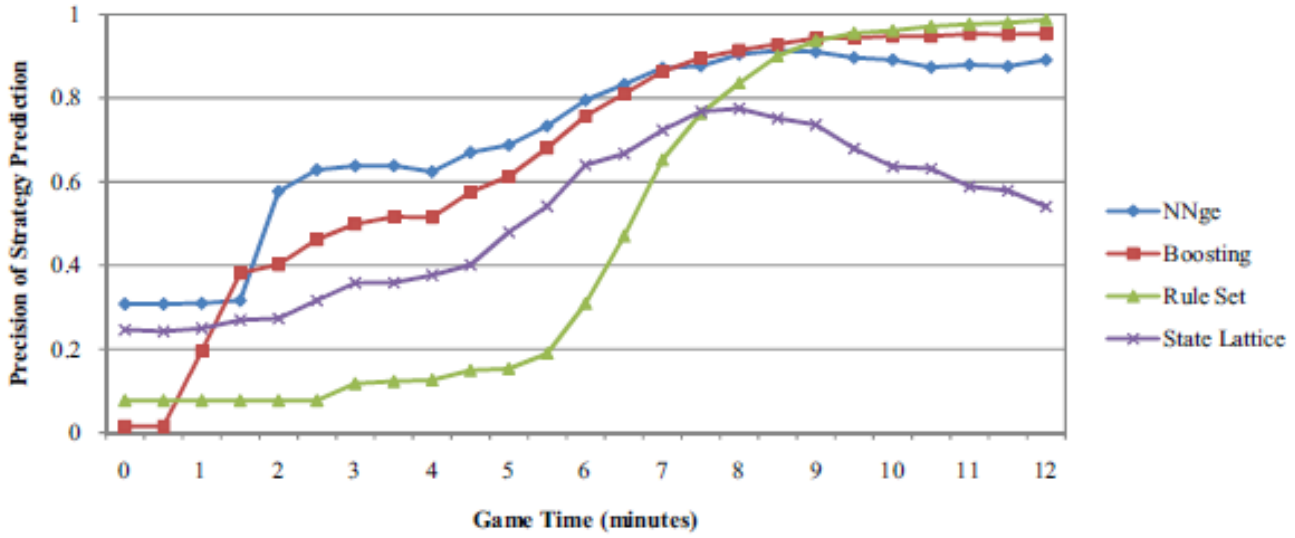


Fig. 1. Friedman test with post-hoc Nemenyi test on the NMI values of the compared approaches. CD is the critical distance.

Pour conclure sur la supériorité d'une approche par rapport à une autre à partir d'un ensemble d'expériences, il est nécessaire d'utiliser un test statistique (par exemple calculer des intervalles de confiance ou utiliser un test de Friedman).

Influence des paramètres



Il est souvent intéressant d'analyser comment varie le critère de comparaison choisi en fonction des valeurs des paramètres de l'expérience.

Par exemple: le temps d'apprentissage, le nombre de processeurs, la taille des données, la valeur d'un paramètre de configuration de l'algorithme, etc...

Critères d’évaluation

Comptage :

- De combien de fois un événement se produit

Durée :

- D'un intervalle de temps

Grandeur :

- De certains paramètres

Une valeur dérivée de ces mesures fondamentales

Propriété d’un bon critère

- **Linéaire**
  - Plus “naturelle”
- **Fiable**
  - Utile pour la comparaison et la prédiction
- **Répétable**
- **Facile à utiliser**
- **Cohérent**
  - La définition est la même dans différents systèmes
- **Indépendant des influences extérieures**

Principaux critères

Qualité d'exécution de la tâche:

- Pourcentage de réussite
- Nombre d'opérations correctes

Vitesse:

- Temps de calcul
- Vitesse de convergence

Efficacité:

- Utilisation des ressources (mémoire,...)
- Parralélisation

Praticité:

- Nombre de paramètres à choisir
- Sensibilité aux paramètres
- Lisibilité/utilisabilité des sorties

A vous de jouer !

Premier rapport (1 page) :

- **Un paragraphe pour expliquer le contexte** :

  ⇒ *Quelle tâche vous intéresse*

  ⇒ *Pourquoi est-ce important*

  ⇒ *Pourquoi est-ce difficile ?*

- **Un paragraphe pour l'état de l'art** :

  ⇒ *Quels sont les principales solutions existantes*

  ⇒ *Quels sont leurs qualités et leurs défauts*

- **Un paragraphe pour le protocol expérimental :**

  ⇒ *Quels sont les conditions expérimentales prévues ?*

  ⇒ *Quels critères d'évaluation allez vous utiliser ?*

Sources

https://www.labri.fr/perso/sutre/ENS-Cachan-Bretagne-2011/Slides/Jeannot.pdf

https://cs.gmu.edu/~setia/cs700-F09/slides/lecture1.pdf